

T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ

BSM 498 BİTİRME ÇALIŞMASI

**MAKİNE ÖĞRENMESİ İLE OLASILIK TABANLI
HİSSE YÖNÜ SINIFLANDIRMA VE KARAR DESTEK
SİSTEMİ**

B221210588 – Younes RAHEBI

Fakülte Anabilim Dalı : BİLGİSAYAR MÜHENDİSLİĞİ
Tez Danışmanı : Doç. Dr. Abdullah SEVİN

2025-2026 Bahar Dönemi

T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ

**MAKİNE ÖĞRENMESİ İLE OLASILIK TABANLI
HİSSE YÖNÜ SINIFLANDIRMA VE KARAR
DESTEK SİSTEMİ**

BSM 498 - BİTİRME ÇALIŞMASI

Younes RAHEBI

Fakülte Anabilim Dalı : BİLGİSAYAR MÜHENDİSLİĞİ

Bu tez .. / .. / ... tarihinde aşağıdaki jüri tarafından oybirliği / oyçokluğu ile kabul edilmiştir.

.....
Jüri Başkanı

.....
Üye

.....
Üye

ÖNSÖZ

Günümüzde küresel finansal piyasalardaki devasa veri hacmi ve artan volatilité, yatırımcıları ve kurumları geleneksel analiz yöntemlerinin ötesine geçmeye zorlamaktadır. Yapay zeka ve makine öğrenmesi teknolojilerinin veri bilimi ile entegrasyonu, sadece geçmişini anlamak için değil, geleceğe yönelik belirsizlikleri yönetmek ve karar alma süreçlerini optimize etmek için de vazgeçilmez bir araç haline gelmiştir. Özellikle finansal zaman serilerinde yüksek gürültüden arındırılmış, olasılık tabanlı ve veri odaklı sistemlerin geliştirilmesi, modern finans teknolojilerinin (FinTech) en kritik çalışma alanlarından biridir.

Bu proje, hisse senedi piyasalarındaki "kesin fiyatı tahmin etme" (regresyon) yanılığını geride bırakarak, piyasa gerçekliğine çok daha uygun olan "yön ve olasılık tahmini" (sınıflandırma) felsefesi üzerine inşa edilmiştir. Geliştirilen Karar Destek Sistemi; teknik göstergeler, piyasa bağlamı ve makro düzeydeki korku endekslerini (VIX) harmanlayarak, kullanıcılara şeffaf ve açıklanabilir bir gelecek projeksiyonu sunmayı amaçlamaktadır.

İÇİNDEKİLER

ÖNSÖZ.....	iii
İÇİNDEKİLER.....	iv
SİMGELER VE KISALTMALAR LİSTESİ.....	vi
ŞEKİLLER LİSTESİ.....	vii
TABLolar LİSTESİ.....	viii
ÖZET.....	ix

BÖLÜM 1.

PROJENİN TEMELLERİ, ÇÖZÜLEN PROBLEM VE SİSTEM MİMARİSİ.....	1
1.1. Proje Ana Tanımı ve Felsefesi.....	1
1.2. Projenin Çözdüğü Problem.....	2
1.3. Genel Çalışma Mantığı ve Kullanıcı Akışı.....	3
1.4. Projenin İç Mimarisi (Kavramsal Modüller).....	4

BÖLÜM 2.

VERİ KAYNAKLARI, ÖN HAZIRLIK VE ÖZELLİK MÜHENDİSLİĞİ....	6
2.1. Temel Veri Kaynakları ve Dışsal Bağlam.....	6
2.2. Veri Ön Hazırlık ve "Tampon Veri" Mantığı.....	6
2.3. Kritik Kavramsal Fark: "Date Range" vs. "Training Window".....	8
2.4. Hedef Değişkenin (Target Variable) Üretimi.....	8
2.5. Özellik Mühendisliği (Feature Engineering) ve Teknik Göstergeler.....	9
2.6. Göreli Güç (Relative Strength) ve Bağlamsal Özellikler.....	11
2.7. Veri Sızıntısını (Data Leakage) Önleme Mekanizmaları.....	11

BÖLÜM 3.

MAKİNE ÖĞRENMESİ MODELLERİ, DOĞRULAMA VE DERİN ANALİZ (DEEP ANALYSIS) MODÜLÜ.....	13
3.1. Kullanılan Makine Öğrenmesi Modelleri.....	13
3.2. Model Eğitimi ve Zaman Serisine Uygun Doğrulama.....	14
3.3. Hiperparametre Optimizasyonu (Tuning).....	15
3.4. Olasılık Kalitesi ve Karar Eşiği (Decision Threshold) Optimizasyonu.....	15
3.5. Performans Metrikleri ve AUC-ROC Önceliği.....	16
3.6. "Deep Analysis" (Derin Analiz) Mekanizması.....	17

BÖLÜM 4.

OLASILIK TABANLI GELECEK PROJEKSİYONU (FUTURE PROJECTION), SINIRLILIKLAR VE SONUÇ.....	19
4.1. Future Projection (Gelecek Projeksiyonu) Felsefesi.....	19
4.2. Projeksiyonun Teknik Mantığı (Adım Adım).....	19
4.3. Görsel Arayüz ve Outlook (Görünüm) Mantığı.....	20
4.4. Neden Tam Fiyat Tahmininden (Regresyondan) Vazgeçildi?.....	21
4.5. Sistemin Sınırlılıkları (Limitations).....	22

BÖLÜM 5.

SONUÇLAR VE ÖNERİLER.....	23
---------------------------	----

KAYNAKLAR.....	24
----------------	----

ÖZGEÇMİŞ.....	25
---------------	----

BSM 498 BİTİRME ÇALIŞMASI DEĞERLENDİRME VE SÖZLÜ SINAV TUTANAĞI.....	26
--	----

SİMGELER VE KISALTMALAR LİSTESİ

ATR	: Ortalama Gerçek Aralık (Average True Range)
AUC-ROC	: Alıcı İşletim Karakteristiği Eğrisi Altında Kalan Alan
CMF	: Chaikin Para Akışı (Chaikin Money Flow)
EMA	: Üssel Hareketli Ortalama (Exponential Moving Average)
ETF	: Borsa Yatırım Fonu (Exchange Traded Fund)
MACD	: Hareketli Ortalama Yakınsama/İraksama (Moving Average Convergence Divergence)
MCC	: Matthews Korelasyon Katsayısı (Matthews Correlation Coefficient)
ML	: Makine Öğrenmesi (Machine Learning)
OBV	: Denge İşlem Hacmi (On-Balance Volume)
OHLCV	: Açılış, En Yüksek, En Düşük, Kapanış, Hacim (Open, High, Low, Close, Volume)
RSI	: Göreli Güç Endeksi (Relative Strength Index)
SMA	: Basit Hareketli Ortalama (Simple Moving Average)
UI	: Kullanıcı Arayüzü (User Interface)
VIX	: CBOE Volatilite Endeksi (Korku Endeksi)

ŞEKİLLER LİSTESİ

Şekil 1.1.	Stock Direction Forecast Uygulaması Ana Kullanıcı Arayüzü.....	2
Şekil 1.2.	Sistem Mimarisi ve Uçtan Uca Veri Akış Diyagramı.....	4
Şekil 1.3.	Uygulama Sol Ayar Paneli (Sidebar) ve Parametre Seçim Arayüzü.....	4
Şekil 1.4.	Projenin 3 Katmanlı Yazılım Mimarisi (Layered Architecture).....	5
Şekil 2.1.	Ham Verinin Görselleştirildiği ve Temel İstatistiklerin Sunulduğu Veri Önizleme Ekranı.....	7
Şekil 2.2.	Modeli Besleyen Teknik Göstergelerin Kullanıcı Arayüzündeki İzduşümü.....	10
Şekil 2.3.	Piyasa Volatilitesi Ölçen ATR ve Hacim İvmesini Gösteren OBV Z-Skor Grafikleri.....	11
Şekil 2.4.	Üretilen Özellikler Arasındaki İlişkileri Gösteren Korelasyon Matrisi.....	12
Şekil 3.1.	Dört Farklı Makine Öğrenmesi Modelinin Performans Metrikleri Açısından Karşılaştırılması.....	14
Şekil 3.2.	Modellerin Güçlü ve Zayıf Yönlerini Gösteren Çok Eksenli Radar Grafiği.....	14
Şekil 3.3.	Seçilen En İyi Modelin Temel Performans Metrikleri ve Optimize Edilmiş Karar Eşiği (Threshold) Özeti.....	16
Şekil 3.4.	Modelin Geçmiş Tahminlerindeki Güven Seviyesi ve Gerçekleşen Sonuçlar (Güven Zaman Çizelgesi).....	16
Şekil 3.5.	Karar Sürecinde En Fazla Ağırlığa Sahip Olan Özellikler (Açıklanabilir Yapay Zeka Çıktısı).....	17
Şekil 3.6.	Derin Analiz Tarama Sonucunda Belirlenen En Optimum Zaman Ufku, Eğitim Penceresi ve Faktör Kombinasyonu....	18
Şekil 3.7.	96 Farklı Kombinasyonun Taranarak En İyi Model Yapılandırmasının Otomatik Bulunması.....	18
Şekil 4.1.	Olasılık Tabanlı Gelecek Senaryo Çizgisi ve Görünüm (Outlook) Seviyeleri.....	21
Şekil 4.2.	İleriye Dönük N-Günlük Projeksiyonun Sayısal Detay Tablosu.....	21

TABLolar LİSTESİ

Tablo 1.1.	Regresyon vs. Sınıflandırma (Classification) Yaklaşımları..	2
Tablo 2.1.	Model Eğitiminde Kullanılan Özellik (Feature) Kategorileri ve Göstergeler.....	10
Tablo 3.1.	Derin Analiz (Deep Analysis) Modülünün Tarama Uzayı ve Kombinasyonları.....	17
Tablo 4.1.	Olasılık Seviyelerine Göre Atanan Görünüm (Outlook) ve Karar Sinyalleri.....	20

ÖZET

Anahtar kelimeler: Makine Öğrenmesi, Finansal Zaman Serileri, Yön Sınıflandırması, Özellik Mühendisliği, Karar Destek Sistemi.

Finansal piyasalarda varlık fiyatlarının tam değerini tahmin etmek; yüksek piyasa gürültüsü, makroekonomik kırılmalar ve irrasyonel yatırımcı psikolojisi nedeniyle oldukça zor ve yüksek hata payı barındıran bir problemdir. Bu çalışma, geleneksel fiyat regresyonu yaklaşımı yerine, belirlenen bir zaman ufkunda (1, 5, 10, 20 gün) hisse senedi yönünün (Yukarı/Aşağı) tahmin edilmesini amaçlayan, makine öğrenmesi tabanlı bir sınıflandırma (classification) ve karar destek sistemi sunmaktadır. Geliştirilen sistem, Yahoo Finance üzerinden alınan OHLCV verilerini temel alarak; trend, momentum, volatilité ve hacim tabanlı teknik göstergeleri hesaplamakta ve bunları Market (Endeks), VIX (Korku Endeksi) ve Sektör ETF verileriyle birleştirerek kapsamlı bir özellik mühendisliği (feature engineering) süreci yürütmektedir.

Çalışma kapsamında Lojistik Regresyon, Random Forest, XGBoost ve LightGBM algoritmaları kullanılmış olup, modellerin eğitimi finansal verinin doğasına uygun olarak zaman serisi doğrulaması (TimeSeriesSplit) ve veri sızıntısını önleyen ufuk boşluğu (gap=horizon) yöntemiyle gerçekleştirilmiştir. Performans ölçümü için AUC-ROC, MCC ve Dengeli Doğruluk (Balanced Accuracy) gibi metrikler kullanılmıştır. Projenin en belirgin yeniliği olan "Derin Analiz" (Deep Analysis) modülü, 96 farklı konfigürasyonu otomatik tarayarak hisseye ve döneme en uygun model yapılandırmasını bulmaktadır.

Elde edilen sonuçlar, kesin fiyat tahmini yapmaya çalışan regresyon modellerinin aksine, sınıflandırma mimarisinin çok daha dirençli ve savunulabilir olduğunu; üretilen yükseliş olasılıklarının (Probability of Up) tarihsel getiri ortalamalarıyla birleştirilmesiyle oluşturulan "Gelecek Projeksiyonu" (Future Projection) modülünün karar vericiler için oldukça rasyonel bir senaryo analizi sunduğunu ortaya koymuştur.

BÖLÜM 1. PROJENİN TEMELLERİ, ÇÖZÜLEN PROBLEM VE SİSTEM MİMARİSİ

1.1. Proje Ana Tanımı ve Felsefesi


Bu proje, finansal piyasalardaki klasik "gelecekteki kesin fiyatı tahmin etme" (fiyat regresyonu) yaklaşımını bilinçli bir kararla terk eden modern bir karar destek sistemidir. Sistem, bunun yerine belirli bir zaman ufkunda hissenin yönünün **yukarı mı (Up) yoksa aşağı mı (Down)** olacağını tahmin eden sınıflandırma (classification) tabanlı bir mimariye sahiptir.

Model; teknik göstergeleri, fiyat/hacim davranışlarını, piyasa bağlamını ve sektör dinamiklerini harmanlayarak bir yön tahmini yapar. Nihai amaç, kullanıcıya doğrudan "al/sat" tavsiyesi vermek değil; seçilen hisse için tamamen veri odaklı, olasılık (probability) tabanlı ve görsel olarak açıklanabilir bir öngörü platformu sunmaktır.

Sistem, "5 gün sonra fiyat tam olarak şu seviyede olacak" gibi yanıltıcı bir kesinlik sunmak yerine, "Belirlenen iş günü sonunda fiyatın bugünkü seviyesinin üzerinde olma olasılığı %X'tir" diyerek daha dürüst, şeffaf ve istatistiksel olarak savunulabilir bir sonuç üretir.

Tablo 1.1. Regresyon vs. Sınıflandırma (Classification) Yaklaşımları

Fiyat Regresyonu (Kesin Fiyat Tahmini)	Yön Sınıflandırması (Yön ve Olasılık Tahmini)
Gelecekteki hisse fiyatının tam değerini (nokta atışı) bulmaya çalışır (Örn: "5 gün sonra fiyat tam 145.50 olacak").	Belirli bir vadede fiyatın bugüne göre yukarıda mı yoksa aşağıda mı olacağını tahmin eder (Örn: "5 gün sonra fiyatın yükselme olasılığı %70").
Finansal piyasalardaki yüksek gürültüden (noise) çok fazla etkilenir. Hata payı (error margin) genellikle çok yüksektir.	Sadece yön aradığı için piyasa gürültüsüne karşı daha toleranslıdır ve istatistiksel olarak çok daha güçlü/savunulabilir sonuçlar üretir.
Çıktı olarak tek bir mutlak sayı üretir. Bu durum, piyasanın kaotik yapısı göz önüne alındığında yanıltıcı ve gerçek dışı bir kesinlik vadeder.	Çıktı olarak bir yön etiketi (Up/Down) ve gerçekleşme olasılığı (Probability) üretir. Açıklanabilirliği çok daha yüksektir.
Genellikle doğrudan yatırımcı veya analist kararlarına entegre edilmesi zordur, çünkü hedeflenen fiyata ulaşamaması stratejiyi bozar.	Karar vericiler için çok daha pratiktir; piyasa gerçekliğiyle ve risk yönetimi prensipleriyle doğrudan örtüşür.



Şekil 1.1. Stock Direction Forecast Uygulaması Ana Kullanıcı Arayüzü.

1.2. Projenin Çözdüğü Problem

Finansal piyasalarda fiyatların mutlak seviyesini (tam değerini) isabetli şekilde tahmin etmek son derece zordur. Bu zorluğun temel sebepleri şunlardır:

- Yüksek piyasa gürültüsü (noise)
- Beklenmedik haber akışları ve makroekonomik kırılmalar
- Piyasa rejimindeki ani değişiklikler
- Likidite farklılıkları ve irrasyonel yatırımcı psikolojisi

Bu bağlamda proje, problemi şu şekilde yeniden ve çok daha pratik bir çerçevede tanımlar:


"Seçilen hisse senedi, hedeflenen zaman ufku (horizon) bittiğinde bugünkü kapanış seviyesine göre daha mı yukarıda olacak, yoksa daha mı aşağıda?"

Çoğu yatırımcı ve analist için yön bilgisi (ve bu yönün olasılık derecesi), mutlak bir fiyat seviyesinden çok daha kritik ve eyleme dönüştürülebilir bir veridir.


1.3. Genel Çalışma Mantığı ve Kullanıcı Akışı

Sistem, kullanıcının adım adım parametreleri belirlediği interaktif bir akışla çalışır. Bu akış şu şekildedir:

1. **Varlık Seçimi:** Kullanıcı analiz edilecek hisseyi (Listeden veya Manuel) seçer.
2. **Tarih Aralığı:** Analize dahil edilecek toplam tarih aralığı (Date Range) belirlenir.
3. **Hedef Ufku (Horizon):** Tahminin kaç gün sonrası için yapılacağı seçilir (1, 5, 10 veya 20 gün).
4. **Dışsal Faktörler:** İsteğe bağlı olarak Market (Endeks), VIX (Korku Endeksi) ve Sektör (Sector ETF) verileri modele dahil edilir.
5. **Eğitim Penceresi (Training Window):** Modelin eğitileceği veri derinliği (Tüm Geçmiş, Son 3 Yıl, Son 1 Yıl vb.) seçilir.
6. **Algoritma Seçimi:** Logistic Regression, Random Forest, XGBoost veya LightGBM modellerinden biri seçilir.
7. **Arka Plan İşlemleri:** Sistem veriyi çeker, özellikleri (features) mühendislikten geçirir, hedef değişkeni (target) üretir ve zaman serisine uygun yürüyen doğrulama (time-series validation) ile modeli test eder.
8. **Görselleştirme:** Sonuçlar; tablolar, radar grafikler, güven zaman çizelgesi (confidence timeline) ve özellik önem (feature importance) ekranlarında kullanıcıya sunulur.



Şekil 1.2. Sistem Mimarisi ve Uçtan Uca Veri Akış Diyagramı.




Şekil 1.3. Uygulama Sol Ayar Paneli (Sidebar) ve Parametre Seçim Arayüzü.

1.4. Projenin İç Mimarisi (Kavramsal Modüller)

Bu yazılım, basit bir makine öğrenmesi betiği (script) olmanın ötesinde, 6 ana modülden oluşan uçtan uca bir uygulamadır:

- **Arayüz (UI) Modülü:** Kullanıcı etkileşimlerini alan ayar panelleri, veri sekmeleri, dinamik grafikler ve sonuç sunum ekranlarını yönetir. Streamlit tabanlı modern bir yapıdadır [1].
- **Veri Yükleme Modülü:** Yahoo Finance (YFinance) entegrasyonu ile ana hisse verisini (OHLCV) ve seçilen dış faktörlerin (Benchmark, VIX, Sektör) verilerini indirir.
- **Özellik Mühendisliği (Feature Engineering) Modülü:** Ham fiyat ve hacim verisinden teknik göstergeleri (RSI, MACD, Bollinger vb.) ve piyasaya göre bağlamsal göreceli güç (relative strength) özelliklerini üretir.

- **Modelleme Modülü:** Zaman serisi ayrımını (Time-Series Split) yönetir, algoritmaları eğitir, doğrulama yapar, eşik (threshold) optimizasyonunu gerçekleştirir ve hiperparametre ayarlarını (tuning) uygular.
- **Projeksiyon Modülü:** Elde edilen yukarı yön olasılığını (Up Probability), tarihsel getiri/volatilite istatistikleriyle birleştirerek geleceğe yönelik senaryo bazlı bir projeksiyon haritası çıkarır.
- **Yardımcı (Utility) Modüller:** Renk paletleri, metin formatlayıcılar, sabit parametreler ve sistem içi metrik hesaplama araçlarını barındırır.



Şekil 1.4. Projenin 3 Katmanlı Yazılım Mimarisi (Layered Architecture).

BÖLÜM 2. VERİ KAYNAKLARI, ÖN HAZIRLIK VE ÖZELLİK MÜHENDİSLİĞİ

2.1. Temel Veri Kaynakları ve Dışsal Bağlam

Projenin ana veri kaynağı, Yahoo Finance üzerinden çekilen günlük formattaki OHLCV (Açılış, En Yüksek, En Düşük, Kapanış, Hacim) verileridir. Ancak sistem, hisseyi tek başına, izole bir varlık olarak değerlendirmez; onu piyasa gerçekliği (market context) içine oturtur [2].

Kullanıcı seçimine bağlı olarak modele şu üç dışsal veri (external factor) eklenebilir:


1. **Market Benchmark (Piyasa Endeksi):** Seçilen hissenin borsasına göre otomatik belirlenir (Örn: BIST hisseleri .IS için XU100, Almanya .DE için DAX gibi).
2. **Sector ETF Proxy (Sektör Fonu):** Şirketin faaliyet gösterdiği sektörü temsil eden ETF verisidir (Teknoloji için XLK, Finans için XLF vb.).
3. **VIX (Korku Endeksi):** Genel piyasa volatilitesi ve risk iştahı / korku rejimini modele tanıtan bağımsız bir küresel makro değişkendir.

2.2. Veri Ön Hazırlık ve "Tampon Veri" Mantiğı

Sistem, kullanıcının seçtiği tarih aralığını indirirken doğrudan o aralıkla yetinmez. Örneğin; kullanıcı 2023-03-15 başlangıç tarihini seçtiyse, sistem arka planda **yaklaşık 90 gün öncesinden** başlayan bir veri seti indirir.

Bunun kritik bir nedeni vardır: **Hareketli ortalamalar (SMA 50 vb.) ve diğer gecikmeli (rolling) göstergelerin, seçilen ilk günden itibaren doğru ve eksiksiz hesaplanabilmesi.** Eğer bu tampon veri indirilmeseydi, ilk 50 günün indikatörleri NaN (boş) veya yapay/hatalı olacaktı.

Özellikler (features) hesaplandıktan sonra bu tampon veri kırılır ve veri seti kullanıcının seçtiği asıl aralığa geri getirilir.



Şekil 2.1. Ham Verinin Görselleştirildiği ve Temel İstatistiklerin Sunulduğu Veri Önizleme Ekranı.

2.3. Kritik Kavramsal Fark: "Date Range" vs. "Training Window"

Projenin veri mimarisinde çok önemli bir ayrım bulunmaktadır ve çıktıları doğru okumak için bu farkın bilinmesi şarttır:

- **Date Range (Tarih Aralığı):** Sistemin Yahoo Finance'ten indirdiği, analiz ettiği ve grafiklerini çizdiği toplam tarih havuzudur.
- **Training Window (Eğitim Penceresi):** İndirilen bu tarih havuzu içinde, *makine öğrenmesi modelinin eğitilmesi için* gerçekte ne kadarlık bir kısmın kullanılacağını belirleyen filtredir.

Örnek Senaryo 1: Date Range 3 yıl seçildi ama Training Window Last 1 Year seçildi. Sistem grafikleri 3 yıllık çizer ancak modeli sadece son 1 yıldaki verilerle eğitir.

Örnek Senaryo 2: Date Range 1 yıl seçildi ama Training Window Last 3 Years seçildi. Sistemde 3 yıllık veri olmadığı için mecburen elindeki 1 yılı kullanarak eğitilir.

Rows Used Kavramı: Modelin sonuç ekranında görünen Rows Used değeri, ham indirilen satır sayısı değil; tampon veriler atıldıktan, indikatörler hesaplandıktan ve geleceğe sarkan satırlar çıkarıldıktan sonra eğitime giren "en temiz nihai satır" sayısıdır.

2.4. Hedef Değişkenin (Target Variable) Üretimi

Proje bir sınıflandırma algoritması olduğu için hedef değişken (Target) basit bir "1" veya "0" olarak kodlanır. Sistem bunu şu mantıkla üretir:

Bugünkü kapanış fiyatı ($Close(t)$) ile kullanıcının seçtiği ufuk (horizon) gün sonraki kapanış fiyatı ($Close(t+h)$) karşılaştırılır:

- Eğer $Close(t+h) > Close(t)$ ise **Target = 1 (Yukarı / Up)**
- Eğer yön aşağı veya eşitse **Target = 0 (Aşağı / Down)**

Buradaki ufuk (horizon) 1, 5, 10 veya 20 iş günü olabilir. Hedef değişken üretildikten sonra, veri setinin en sonundaki horizon kadar satır silinir. Çünkü bu son günlerin henüz gelecekteki karşılıkları (gerçekleşmiş fiyatları) belli değildir. Bu işlem, model eğitimindeki sızıntıları önlemek için elzemdir.

2.5. Özellik Mühendisliği (Feature Engineering) ve Teknik Göstergeler

Makine öğrenmesi modelleri sadece ham fiyatları (Açılış, Kapanış vb.) okuyarak başarılı olamazlar. Projenin ana gücü, ham veriden anlamlı istatistiksel sinyaller türeten özellik mühendisliğinde yatar.


Üretilen temel kategoriler ve kullanılan göstergeler şunlardır:

- **Trend ve Momentum:** SMA (7, 21, 50), EMA (12, 26), MACD (Sinyal ve Histogram), RSI, Stochastic Osilatör [3, 4].
- **Volatilite (Oynaklık):** Bollinger Bantları (Genişlik ve Yüzde), ATR (Average True Range).
- **Hacim Baskısı:** OBV (On-Balance Volume), CMF (Chaikin Money Flow), Z-Skorlu hacim değişim oranları.
- **Fiyat Davranışı:** Günlük getiriler, geçmiş 5-10-20 günlük kümülatif getiriler (Return_5d vb.), Gap (Boşluk) getirileri ve gün içi (Intraday) marjlar.

Örneğin; **RSI** fiyatın aşırı alım/satım bölgelerini gösterirken, **Bollinger Bantları** fiyat sıkışmalarını haber verir. **OBV**, fiyat hareketinin "gerçekten hacimle desteklenip desteklenmediğini" ölçer. Model, bunları sadece birer çizgi olarak değil, matematiksel karar düğümleri olarak değerlendirir.

Tablo 2.1. Model Eğitiminde Kullanılan Özellik (Feature) Kategorileri ve Göstergeler

Özellik Kategorisi	Kullanılan Göstergeler / Değişkenler	Sisteme Sağladığı Bilgi (Amaç)
Trend ve Momentum	SMA (7, 21, 50), EMA (12, 26), MACD, RSI, Stochastic	Fiyatın genel yönelimini, aşırı alım/satım bölgelerini ve trendin gücünü ölçer.
Volatilité (Oynaklık)	Bollinger Bantları, ATR, Volatilité Rejimi	Fiyatın ne kadar dalgalı olduğunu ve olası kırılma (breakout) noktalarını belirler.
Hacim Baskısı	OBV, OBV Z-Skor, CMF, Hacim Değişim Oranları	Fiyat hareketinin gerçek bir para girişi/çıkışı ile desteklenip desteklenmediğini teyit eder.
Dışsal Bağlam	VIX (Korku Endeksi), Market Benchmark, Sector ETF	Küresel risk iştahını ve hissenin içinde bulunduğu pazarın/sektörün genel durumunu modele tanıtır.
Görelî Güç (Relative)	Beta, Rolling Korelasyon, Relative Return (Görelî Getiri)	Hissenin piyasaya veya sektöre kıyasla pozitif/negatif ayrışma (outperform/underperform) durumunu ölçer.



Şekil 2.2. Modeli Besleyen Teknik Göstergelerin Kullanıcı Arayüzündeki İzdüşümü.



Şekil 2.3. Piyasa Volatilitesini Ölçen ATR ve Hacim İvmesini Gösteren OBV Z-Skor Grafikleri.

2.6. Görelî Güç (Relative Strength) ve Bağlamsal Özellikler

Bu proje, hisseyi sadece kendi geçmişiyle değil, çevresiyle de kıyaslar. "Hisse yükseldi mi?" sorusu yetersizdir; "Hisse piyasadan veya kendi sektöründen daha mı güçlü durdu?" sorusu modele asıl başarıyı getiren detaydır.

Bunun için şu "Görelî" özellikler türetilir:

- `Relative_Return_5d` (Hissenin 5 günlük getirisinin, Market'in 5 günlük getirisine kıyasla durumu)
- `Rolling_Corr_Market_20` (Hissenin son 20 günde endeksle olan korelasyonu)
- `Beta_Market_20` (Piyasa volatilitesine karşı hissenin duyarlılığı)
- `Trend_Strength_vs_Sector_20` (Sektör ETF'ine göre trend gücü)

2.7. Veri Sızıntısını (Data Leakage) Önleme Mekanizmaları

Finansal makine öğrenmesi projelerindeki en büyük hata, modelin test edileceği "gelecek" bilgisini yanlışlıkla eğitim (training) aşamasında görmesidir (Look-ahead bias). Projede bunu engellemek için askeri disiplinde kurallar uygulanmıştır:

1. **Zaman Serisi Validasyonu:** Veri asla rastgele (Random Split) bölünmez. `TimeSeriesSplit` kullanılarak kronolojik sıra korunur [5].
2. **Gap = Horizon Kuralı:** Eğitim verisi ile test verisi arasına, seçilen horizon (hedef ufku) kadar kör nokta (gap) bırakılır. Böylece test gününün sonucu, eğitim günlerine sızamaz.

3. Gecikmeli Dış Veri: Endeks ve VIX gibi dışsal veriler aynı gün bilgisi sızdırmaması adına gecikmeli (lagged) olarak modele yedirilir.



Şekil 2.4. Üretilen Özellikler Arasındaki İlişkileri Gösteren Korelasyon Matrisi.

BÖLÜM 3. MAKİNE ÖĞRENMESİ MODELLERİ, DOĞRULAMA VE DERİN ANALİZ (DEEP ANALYSIS) MODÜLÜ

3.1. Kullanılan Makine Öğrenmesi Modelleri

Sistem, yön sınıflandırması (Up/Down classification) problemini çözmek için farklı yaklaşımlara sahip dört güçlü makine öğrenmesi modelini aynı anda eğitir ve karşılaştırır:

- **Logistic Regression (Lojistik Regresyon):** Projenin doğrusal (lineer) ve en açıklanabilir temel (baseline) modelidir. Veriler StandardScaler ile ölçeklendirilerek kullanılır. Ağaç tabanlı modellerin aksine, lojistik regresyon doğal olarak olasılık (probability) üreten bir yapıda olduğu için gereksiz bir ikinci kalibrasyon katmanına sokulmaz; ancak karar eşiği (threshold) optimizasyonu bu modele de uygulanır. Kısa pencerelerde (örn: Son 1 Yıl) lineer sinyaller çok güçlü olabildiğinden, lojistik regresyon bazı konfigürasyonlarda en karmaşık modelleri bile geride bırakabilmektedir [6].
- **Random Forest:** Karar ağaçlarının topluluk (ensemble) versiyonudur. Doğrusal olmayan karmaşık örüntüleri yakalayabilir. Finansal verilerdeki gürültüye karşı görece dayanıklı, klasik ve sağlam bir algoritmadır [6].
- **XGBoost:** Gradient boosting (gradyan artırma) tabanlı son derece güçlü bir modeldir. Özellikle üretilen özellikler (features) arasındaki gizli etkileşimleri öğrenmede çok başarılıdır [7].
- **LightGBM:** XGBoost benzeri mantıkla çalışan ancak daha büyük özellik uzaylarında çok daha hızlı ve verimli olan, yaprak odaklı (leaf-wise) bir boosting algoritmasıdır [8].

Model Comparison								
Model	Accuracy (%)	Balanced Accuracy (%)	Macro Precision (%)	Macro Recall (%)	Macro F1-Score (%)	MCC	AUC-ROC (%)	Decision Threshold (%)
Logistic Regression	77.62	77.52	77.49	77.52	77.50	0.550	81.95	50.00
Random Forest	51.43	50.27	50.29	50.27	49.60	0.006	35.03	50.00
XGBoost	52.86	51.16	51.44	51.16	49.39	0.026	47.83	50.00
LightGBM	53.33	50.51	51.12	50.51	43.93	0.015	45.47	50.00

Şekil 3.1. Dört Farklı Makine Öğrenmesi Modelinin Performans Metrikleri Açısından Karşılaştırılması.



Şekil 3.2. Modellerin Güçlü ve Zayıf Yönlerini Gösteren Çok Eksenli Radar Grafiği.

3.2. Model Eğitimi ve Zaman Serisine Uygun Doğrulama

Modeller, geleneksel makine öğrenmesi projelerindeki gibi rastgele (random k-fold) bölünerek eğitilmez. Finansal veriler kronolojiktir; bu nedenle TimeSeriesSplit (Zaman Serisi Bölünmesi) kullanılır.

Temel mantık şudur:

1. Model geçmiş veride eğitilir.
2. Gelecekteki veri (kronolojik olarak sonradan gelen) test için ayrılır.
3. Eğitim ve test verisi arasında gap = horizon (seçilen ufuk gün sayısı) kadar bir "boşluk" bırakılır.

Bu katı kural sayesinde model, test dönemine ait hiçbir gelecek bilgiyle kirlenmez ve piyasa koşullarında karşılaşıacağı gerçek "Out-of-Sample" (örneklem dışı) senaryosuna en yakın şekilde test edilmiş olur.

3.3. Hiperparametre Optimizasyonu (Tuning)

Kullanıcı arayüzden Hyperparameter Tuning seçeneğini aktif ettiğinde, sistem varsayılan model ayarlarıyla yetinmez. Bunun yerine RandomizedSearchCV yöntemiyle her model için hiperparametre uzayını tarar.

- Ağaç tabanlı modellerde derinlik, öğrenme oranı, dal sayısı gibi parametreler optimize edilirken;
- Lojistik Regresyon için özellikle ceza katsayısı (C değeri) üzerinden optimizasyon yapılır.

Tuning işlemi eğitim süresini uzatsa da, modele esneklik katar ve veriye aşırı uyum (overfitting) problemini minimize eder.


3.4. Olasılık Kalitesi ve Karar Eşiği (Decision Threshold) Optimizasyonu

Bu projenin en kritik özelliklerinden biri, modelin sadece "Yukarı" veya "Aşağı" gibi kesin bir sınıf etiketi vermekle kalmayıp, bunun **olasılığını (Probability of Up)** üretmesidir.

Sınıflandırma algoritmaları varsayılan olarak karar eşiğini %50 (0.50) kabul eder. Ancak finansal verilerde sınıflar veya piyasa rejimleri her zaman simetrik değildir. Bu nedenle sistem körü körüne %50 eşiğini kullanmaz:

- Sistem 0.30 ile 0.70 arasındaki aday eşik (threshold) değerlerini tarar.
- Bu taramada; Macro Recall, Macro F1, Accuracy ve eşiğin 0.5'e yakınlığı gibi çoklu ölçütler değerlendirilir.
- En dengeli kararı veren eşik seçilir.

Bu sayede sistemin Bullish (Yükseliş) veya Bearish (Düşüş) kararı, o hissenin mevcut veri yapısına ve volatilitesine göre dinamik olarak uyarlanır.



Şekil 3.3. Seçilen En İyi Modelin Temel Performans Metrikleri ve Optimize Edilmiş Karar Eşiği (Threshold) Özeti.




Şekil 3.4. Modelin Geçmiş Tahminlerindeki Güven Seviyesi ve Gerçekleşen Sonuçlar (Güven Zaman Çizelgesi).

3.5. Performans Metrikleri ve AUC-ROC Önceliği

Sistem; Accuracy, Balanced Accuracy, Macro Precision, Macro Recall, Macro F1 ve MCC (Matthews Correlation Coefficient) gibi çeşitli metrikleri hesaplar. Ancak projede **en iyi modeli seçmek için kullanılan ana (birincil) metrik AUC-ROC (Area Under the Receiver Operating Characteristic Curve)** değeridir.

Neden AUC-ROC?

Çünkü bu sistem "Probability-Driven" (Olasılık Odaklı) çalışır. AUC, bir modelin yukarı yönlü olasılıkları sıraya dizme (ranking) yeteneğini ve iki sınıfı (Up/Down) birbirinden ayırt etme kalitesini en iyi ölçen metriktir. Dengesiz veri setlerinde saf Accuracy (Doğruluk) yanıltıcı olabilirken, AUC-ROC modelin gerçek ayırım gücünü yansıtır.



Şekil 3.5. Karar Sürecinde En Fazla Ağırlığa Sahip Olan Özellikler (Açıklanabilir Yapay Zeka Çıktısı).

3.6. "Deep Analysis" (Derin Analiz) Mekanizması

Projenin en inovatif ve otomatize edilmiş "oyun değiştirici" bölümü Deep Analyze Best Setup modülüdür. Kullanıcı tek bir ufuk veya faktör setine bağlı kalmak yerine, bu butona bastığında sistem devasa bir arama uzayına girer.

Tablo 3.1. Derin Analiz (Deep Analysis) Modülünün Tarama Uzayı ve Kombinasyonları

Parametre Sınıfı	Taranan Seçenekler	Kombinasyon Çarpanı
Hedef Ufku (Horizon)	1 Gün, 5 Gün, 10 Gün, 20 Gün	4 Seçenek
Eğitim Penceresi	Son 1 Yıl, Son 2 Yıl, Son 3 Yıl	3 Seçenek
Dışsal Faktör Seti	Sadece Teknik, Sadece Market, Sadece VIX, Sadece Sektör, Market+VIX, Market+Sektör, VIX+Sektör, Tümü (Market+VIX+Sektör)	8 Seçenek
Toplam Tarama Hacmi	4 Ufuk × 3 Pencere × 8 Faktör Seti = 96 Benzersiz Sistem Yapılandırması	96 Setup

Sistem bu 96 yapılandırmayı hızlı karşılaştırma modunda eğitip test eder. Tüm konfigürasyonlar AUC-ROC, Balanced Accuracy ve MCC önceliklendirmesiyle sıralanır. En üst sıraya çıkan kombinasyon (Best Setup) "Şampiyon" ilan edilir ve kullanıcı arayüzündeki tüm sekmeler bu en iyi konfigürasyon ile yeniden inşa edilir. Bu yaklaşım, hisseye göre "ezbere" ayar yapmayı engeller; verinin kendi en iyi ayarını söylemesini sağlar.



Şekil 3.6. Derin Analiz Tarama Sonucunda Belirlenen En Optimum Zaman Ufku, Eğitim Penceresi ve Faktör Kombinasyonu.

Deep Analysis Ranking

	Horizon (days)	Training Window	Factors	Best Model	Rows Used	Accuracy (%)	Balanced Accuracy (%)	Macro Precision (%)	Macro Recall (%)	Macro F1-Score (%)	MCC	AUC-ROC (%)
0	20	Last 1 Year	Market + Sector	Logistic Regression	252	76.19	76.27	76.13	76.27	76.14	0.524	85.75
1	20	Last 1 Year	Market + VIX + Sector	Logistic Regression	252	75.24	75.46	75.32	75.46	75.22	0.508	84.92
2	20	Last 1 Year	Sector Only	Logistic Regression	252	74.76	74.43	74.67	74.43	74.51	0.491	83.58
3	20	Last 1 Year	VIX + Sector	Logistic Regression	252	74.76	74.65	74.62	74.65	74.63	0.493	83.29
4	20	Last 1 Year	Market + VIX	Logistic Regression	252	68.57	68.97	68.97	68.97	68.57	0.379	78.17
5	20	Last 1 Year	Market Only	Logistic Regression	252	66.19	66.61	66.64	66.61	66.19	0.333	77.45
6	20	Last 1 Year	Technical Only	Logistic Regression	252	62.38	61.83	62.08	61.83	61.84	0.239	75.09
7	20	Last 1 Year	VIX Only	Logistic Regression	252	62.86	62.42	62.57	62.42	62.44	0.250	75.00
8	20	Last 2 Years	Market + VIX + Sector	Logistic Regression	504	58.10	57.40	57.80	57.40	57.16	0.152	68.49
9	20	Last 2 Years	Market + VIX	Logistic Regression	504	61.43	60.78	61.30	60.78	60.62	0.221	67.99
10	20	Last 2 Years	Market + Sector	Logistic Regression	504	54.05	53.12	53.42	53.12	52.45	0.065	67.20
11	20	Last 2 Years	Market Only	Logistic Regression	504	55.00	53.89	54.46	53.89	52.88	0.083	67.08
12	10	Last 2 Years	Technical Only	Logistic Regression	504	65.00	64.95	64.98	64.95	64.96	0.299	66.99
13	5	Last 1 Year	Market + VIX + Sector	Logistic Regression	252	55.71	56.22	58.56	56.22	52.70	0.146	64.47

Şekil 3.7. 96 Farklı Kombinasyonun Taranarak En İyi Model Yapılandırmasının Otomatik Bulunması.

BÖLÜM 4. OLASILIK TABANLI GELECEK PROJEKSİYONU (FUTURE PROJECTION), SINIRLILIKLAR VE SONUÇ

4.1. Future Projection (Gelecek Projeksiyonu) Felsefesi

Uygulamanın en çok dikkat çeken sekmesi olan "Future Projection", elde edilen makine öğrenmesi sonuçlarını ileriye dönük bir senaryoya dönüştürür. Ancak burada çok kritik bir ayrım vardır: **Bu modül, gelecekteki fiyatı doğrudan regresyonla tahmin eden bir "kristal küre" değildir.**

Bu bölüm, mutlak bir fiyat vaadi sunmak yerine, olasılık tabanlı bir **senaryo motoru (scenario engine)** olarak çalışır. Amacı, modelin "Yukarı" (Up) olasılığını tarihsel istatistiklerle harmanlayarak mantıklı ve veriye dayalı bir beklenti bandı oluşturmaktır.

4.2. Projeksiyonun Teknik Mantığı (Adım Adım)

Gelecek fiyat senaryosu ve güven aralıkları (confidence bands) şu adımlarla hesaplanır:

1. **Olasılık Üretimi:** Seçilen model (örn. XGBoost), gelecek "N" gün için bir yukarı çıkma olasılığı (Up Probability) üretir.
2. **Tarihsel Getiri Analizi:** Sistem, hissenin geçmişteki hedeflenen zaman ufku (horizon) bazlı ortalama yukarı yönlü (*Up_Return*) ve aşağı yönlü (*Down_Return*) hareket büyüklüklerini hesaplar.
3. **Beklenen Getiri (Expected Horizon Return):** Modelin ürettiği olasılık, bu tarihsel ortalama hareket büyüklükleriyle ağırlıklandırılarak birleştirilir.
4. **Bileşik Eşdeğer:** Bulunan beklenen ufuk getirisi, günlük bileşik getiri eşdeğerine çevrilir.

5. **Senaryo Yolunun Çizilmesi:** Bu günlük oran kullanılarak, bugünkü fiyattan itibaren geleceğe doğru adım adım bir senaryo fiyat yolu çizilir.
6. **Güven Bandı (Confidence Band):** Hissenin tarihsel volatilitesi kullanılarak (kullanıcının seçtiği %80, %90, %95 veya %99 güven aralığı senaryolarına göre) bu fiyat yolunun etrafına bir sapma bandı eklenir.


4.3. Görsel Arayüz ve Outlook (Görünüm) Mantığı

Future Projection sekmesi, sonucu salt rakamlarla değil, görsel renk kodlarıyla ve sinyallerle kullanıcıya sunar.

Grafik üzerinde zaman eksenini (gelecekteki iş günleri) yer alır. Karar eşiğinin (threshold) altı kırmızı bölge, üstü ise yeşil bölge olarak renklendirilir. Modelin ürettiği olasılık değerine göre sistem hisseye dinamik bir **Outlook (Görünüm)** atar.

Tablo 4.1. Olasılık Seviyelerine Göre Atanan Görünüm (Outlook) ve Karar Sinyalleri

Yukarı Yön Olasılığı (Up Probability)	Atanan Görünüm (Outlook) Etiketleri	Grafik Rengi / Bölge	Karar Sinyali
%70 ve Üzeri	Strong Bullish (Güçlü Yükseliş)	Koyu Yeşil	▲ Bullish
%60 - %69 arası	Bullish (Yükseliş)	Açık Yeşil	▲ Bullish
%40 - %59 arası	Neutral (Nötr / Yatay)	Gri / Sarı	Sinyal Yok
%30 - %39 arası	Bearish (Düşüş)	Açık Kırmızı	▼ Bearish
%30'dan Küçük	Strong Bearish (Güçlü Düşüş)	Koyu Kırmızı	▼ Bearish



Şekil 4.1. Olasılık Tabanlı Gelecek Senaryo Çizgisi ve Görünüm (Outlook) Seviyeleri.

Projection Details										
Day	Date	Probability of Up (%)	Signal	Outlook	Projected Price	Projected Change (%)	Est. 20-Day Return (%)	Applied Daily Return (%)	Lower Bound	Upper Bound
1	2026-03-18 (Wednesday)	1.9	▼ Bearish	Strong Bearish	293.84	-0.31	-5.989	-0.308	281.87	305.81
2	2026-03-19 (Thursday)	3.3	▼ Bearish	Strong Bearish	292.97	-0.6	-5.777	-0.297	276.09	309.85
3	2026-03-20 (Friday)	6.6	▼ Bearish	Strong Bearish	292.17	-0.88	-5.305	-0.272	271.55	312.79
4	2026-03-23 (Monday)	7.8	▼ Bearish	Strong Bearish	291.4	-1.14	-5.122	-0.263	267.66	315.14
5	2026-03-24 (Tuesday)	9.5	▼ Bearish	Strong Bearish	290.68	-1.38	-4.881	-0.25	264.2	317.16
6	2026-03-25 (Wednesday)	13.2	▼ Bearish	Strong Bearish	290.03	-1.6	-4.34	-0.222	261.09	318.97
7	2026-03-26 (Thursday)	16	▼ Bearish	Strong Bearish	289.45	-1.8	-3.931	-0.2	258.25	320.65
8	2026-03-27 (Friday)	18.4	▼ Bearish	Strong Bearish	288.92	-1.98	-3.588	-0.183	255.63	322.21
9	2026-03-30 (Monday)	29.1	▼ Bearish	Strong Bearish	288.63	-2.08	-2.026	-0.102	253.35	323.91
10	2026-03-31 (Tuesday)	39.5	▼ Bearish	Bearish	288.55	-2.1	-0.502	-0.025	251.37	325.73

CURRENT PRICE
294.75

DAY 30 UP PROBABILITY
64.1%
 +14.1 pts

FINAL OUTLOOK
Bullish
 + Bullish

SCENARIO RANGE (95%)
229.68 - 361.62
 +10.31%

Şekil 4.2. İleriye Dönük N-Günlük Projeksiyonun Sayısal Detay Tablosu.

4.4. Neden Tam Fiyat Tahmininden (Regresyondan) Vazgeçildi?

Bu proje kavramsal olarak başlarken regresyon tabanlı bir fiyat tahmini hedeflenmiş olsa da, geliştirme sürecinde bilinçli bir kararla "sınıflandırma öncelikli" (classification-first) mimariye geçilmiştir. Bu stratejik kararın nedenleri şunlardır:

- **Yüksek Gürültü:** Regresyonla tam fiyat tahmini, finansal zaman serilerindeki mikro gürültülerden aşırı etkilenir.
- **Zayıf Out-of-Sample Performansı:** Regresyon modelleri eğitim verisinde mükemmel sonuçlar verse de, gerçek dünya testlerinde (out-of-sample) hızla yanılır ve yanıltıcı bir kesinlik sunar.

- **Kullanıcı Pratiği:** Bir analist veya yatırımcı için fiyatın tam olarak nerede duracağından ziyade, "yönün ne tarafa olacağı" ve "bu yönün olasılık gücü" pratik hayatta çok daha uygulanabilir bir bilgidir.

4.5. Sistemin Sınırlılıkları (Limitations)

Akademik ve profesyonel etiğin bir gereği olarak, sistemin zayıf veya sınırlı yönleri dürüstçe vurgulanmalıdır:

- **Yatırım Tavsiyesi Değildir:** Üretilen çıktılar kesinlikle finansal tavsiye niteliği taşımaz; sadece istatistiksel bir karar destek aracıdır.
- **Temel Analiz ve Haber Eksikliği:** Sistem tamamen fiyat, hacim ve teknik/bağlamsal özelliklere odaklanır. Şirket bilançoları, anlık haber akışları (sentiment) veya CEO açıklamaları gibi metin/duygu tabanlı veriler entegre edilmemiştir.
- **Rejim Kırılmaları:** Sonuçlar, öngörülemeyen "Siyah Kuğu" (Black Swan) olaylarından veya çok sert kısa dönem piyasa rejimi değişimlerinden doğrudan etkilenebilir.
- **Evrensel Bir "En İyi" Yoktur:** Aynı model veya eğitim penceresi tüm hisselerde en iyi sonucu vermez; bu yüzden sistem "Deep Analysis" modülüyle hisseye özel adaptif bir arama yapar.

BÖLÜM 5. SONUÇLAR VE ÖNERİLER

Bu projede geliştirilen makine öğrenmesi tabanlı karar destek sistemi, finansal zaman serilerindeki yüksek gürültüye karşı geleneksel fiyat regresyonu yerine, yön ve olasılık (sınıflandırma) tahmininin çok daha başarılı ve tutarlı olduğunu kanıtlamıştır. Sistemin, hissenin kendi geçmişine ek olarak VIX (Korku Endeksi), piyasa endeksi ve sektör verilerini kullanması algoritmaların ayırt etme gücünü belirgin şekilde artırmıştır. "Derin Analiz" modülü sayesinde 96 farklı konfigürasyon taranarak her varlık için en uygun yapılandırma otomatik bulunmuş, zaman serisine uygun doğrulama (gap=horizon) kuralı ile veri sızıntısı (look-ahead bias) tamamen engellenmiştir. Elde edilen yön olasılıklarının tarihsel ortalamalarla birleştirilerek "Gelecek Projeksiyonu" olarak sunulması, karar vericilere gerçekçi ve eyleme dönüştürülebilir senaryolar sağlamıştır.

Sistemin öngörü yeteneğini ve sektörel potansiyelini daha da ileriye taşımak adına bazı geliştirmeler önerilmektedir. Gelecek çalışmalarda finansal haberler, şirket bilançoları ve sosyal medyadan elde edilecek duygu analizi (NLP) skorlarının modele entegre edilmesi büyük önem taşımaktadır. Ayrıca, faiz ve enflasyon gibi makroekonomik verilerin dışsal faktörlere eklenmesi sistemin kriz dönemlerindeki adaptasyonunu artıracaktır. Mevcut günlük veri mimarisinin anlık (saatlik/tick) işlem verilerini destekleyecek şekilde genişletilmesi ve sistemin hisse senetleri dışında kripto para veya emtia gibi farklı finansal piyasalara uyarlanması, projenin kullanım alanını maksimize edecek öncelikli hedefler arasındadır.

KAYNAKLAR

- [1] <https://docs.streamlit.io/>, Erişim Tarihi: 25.05.2026.
- [2] <https://pypi.org/project/yfinance/>, Erişim Tarihi: 25.05.2026.
- [3] ACHELIS, SB., Technical analysis from A to Z. McGraw-Hill: New York, 2000.
- [4] ARONSON, DR., Evidence-based technical analysis: Applying the scientific method and statistical inference to trading signals. John Wiley & Sons: New Jersey, 2006.
- [5] LOPEZ DE PRADO, M., Advances in financial machine learning. John Wiley & Sons: New York, 2018.
- [6] PEDREGOSA, F., VAROQUAUX, G., GRAMFORT, A., MICHEL, V., THIRION, B., GRISEL, O., BLONDEL, M., PRETTENHOFER, P., WEISS, R., DUBOURG, V., VANDERPLAS, J., PASSOS, A., COURNAPEAU, D., Scikit-learn: Machine learning in Python. J. Mach. Learn. Res., 12:2825-2830, 2011.
- [7] CHEN, T., GUESTRIN, C., XGBoost: A scalable tree boosting system. In Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining, San Francisco, U.S.A, pp. 785-794, 2016.
- [8] KE, G., MENG, Q., FINLEY, T., WANG, T., CHEN, W., MA, W., YE, Q., LIU, TY., LightGBM: A highly efficient gradient boosting decision tree. Adv. Neural Inf. Process. Syst., 30:3146-3154, 2017.

ÖZGEÇMİŞ

Younes Rahebi, 16.09.2000 tarihinde Gonbad-e Kavus'ta doğdu. 2022 yılında Sakarya Üniversitesi Bilgisayar Mühendisliği Bölümü'nde lisans eğitimine başlamış olup, eğitimine son sınıf öğrencisi olarak devam etmektedir. Lisans sürecinde veri bilimi ve makine öğrenmesi alanlarına yönelmiş, Python ile veri analizi ve model geliştirme üzerine çeşitli akademik ve kişisel projeler yürütmüştür. 2024-2025 yılları arasında Kadir Has Üniversitesi'nde TÜBİTAK destekli bir projede araştırma stajyeri olarak görev almış; literatür taraması, teknik dokümantasyon ve makale hazırlık çalışmalarına katkı sunmuştur. Ayrıca Artes Solution firmasında yazılım geliştirme ve donanım/IoT stajları yaparak .NET Core MVC tabanlı web uygulamaları geliştirmiş, Arduino tabanlı prototipler ve sensör tabanlı gömülü sistemler üzerinde çalışmıştır.

BSM 498 BİTİRME ÇALIŞMASI DEĞERLENDİRME VE SÖZLÜ SINAV TUTANAĞI

KONU :

ÖĞRENCİLER (Öğrenci No/AD/SOYAD):

Değerlendirme Konusu	İstenenler	Not Aralığı	Not
Yazılı Çalışma			
Çalışma klavuza uygun olarak hazırlanmış mı?	x	0-5	
Teknik Yönden			
Problemin tanımı yapılmış mı?	x	0-5	
Geliştirilecek yazılımın/donanımın mimarisini içeren blok şeması (yazılımlar için veri akış şeması (dfd) da olabilir) çizilerek açıklanmış mı?			
Blok şemadaki birimler arasındaki bilgi akışına ait model/gösterim var mı?			
Yazılımın gereksinim listesi oluşturulmuş mu?			
Kullanılan/kullanılması düşünülen araçlar/teknolojiler anlatılmış mı?			
Donanımların programlanması/konfigürasyonu için yazılım gereksinimleri belirtilmiş mi?			
UML ile modelleme yapılmış mı?			
Veritabanları kullanılmış ise kavramsal model çıkarılmış mı? (Varlık ilişki modeli, noSQL kavramsal modelleri v.b.)			
Projeye yönelik iş-zaman çizelgesi çıkarılarak maliyet analizi yapılmış mı?			
Donanım bileşenlerinin maliyet analizi (prototip-adetli seri üretim vb.) çıkarılmış mı?			
Donanım için gerekli enerji analizi (minimum-uyku-aktif-maksimum) yapılmış mı?			
Grup çalışmalarında grup üyelerinin görev tanımları verilmiş mi (iş-zaman çizelgesinde belirtilebilir)?			
Sürüm denetim sistemi (Version Control System; Git, Subversion v.s.) kullanılmış mı?			
Sistemin genel testi için uygulanan metotlar ve iyileştirme süreçlerinin dökümü verilmiş mi?			
Yazılımın sızma testi yapılmış mı?			
Performans testi yapılmış mı?			
Tasarımın uygulamasında ortaya çıkan uyumsuzluklar ve aksaklıklar belirtilerek çözüm yöntemleri tartışılmış mı?			
Yapılan işlerin zorluk derecesi?	x	0-25	
Sözlü Sınav			
Yapılan sunum başarılı mı?	x	0-5	
Soruları yanıtlama yetkinliği?	x	0-20	
Devam Durumu			
Öğrenci dönem içerisindeki raporlarını düzenli olarak hazırladı mı?	x	0-5	
Diğer Maddeler			
Toplam			

DANIŞMAN (JÜRİ ADINA):

DANIŞMAN İMZASI: